

Resumen Teoria

Árboles en Bases de Datos

Los árboles son estructuras jerárquicas utilizadas para organizar datos de manera eficiente, permitiendo operaciones rápidas de inserción, búsqueda y eliminación. A continuación, se detallan los principales tipos:

Árboles Binarios

- **Definición:** Árboles donde cada nodo tiene máximo dos hijos (izquierdo y derecho).
- **Usos comunes:**
 - Representación de expresiones aritméticas.
 - Árboles de decisión en algoritmos.
- **Ventajas:**
 - Simplicidad en la implementación.
 - Búsqueda eficiente si está balanceado.
- **Desventajas:**
 - Desperdicio de espacio en nodos vacíos.
 - Baja eficiencia si no está balanceado (altura desproporcionada).

Árboles AVL

- **Definición:** Árbol binario de búsqueda auto-balanceado.
- **Características clave:**
 - La altura de los subárboles de cualquier nodo difiere en máximo 1.
 - Usa rotaciones (simple o doble) para mantener el equilibrio.
- **Ventajas:**
 - Búsqueda en tiempo $O(\log n)$.
 - Ideal para aplicaciones con inserciones/eliminaciones frecuentes.
- **Desventajas:**
 - Complejidad en la implementación de rotaciones.

Característica	Árbol Binario	Árbol AVL
Balanceo	No garantizado	Auto-balanceado
Complejidad de búsqueda	$O(n)$ en peor caso	$O(\log n)$ siempre
Uso de memoria	Menor	Mayor (almacena alturas)
Caso de uso	Datos estáticos	Datos dinámicos

Árboles Multicamino (B y B+)

- **Definición:** Árboles donde cada nodo puede tener múltiples hijos ($N > 2$).
- **Propósito:** Reducir la altura del árbol para minimizar accesos a disco.

Árbol B

- **Características:**
 - Todos los nodos (hojas y no hojas) almacenan claves.
 - Cada nodo tiene entre $\lceil m/2 \rceil$ y m hijos (donde m es el orden del árbol).
- **Ventajas:**
 - Eficiente para sistemas de almacenamiento en disco.
 - Inserción y eliminación sin necesidad de rebalanceo frecuente.

Árbol B+

- **Características:**
 - Las claves se duplican en nodos hoja.
 - Nodos internos actúan como índices.
- **Ventajas:**
 - Recorrido secuencial eficiente gracias a punteros en nodos hoja.
 - Mayor densidad de almacenamiento.

Árboles AVL

Política de Inserción Mejorada

- **Redistribución antes de la división:**

Cuando un nodo alcanza su capacidad máxima, en lugar de dividirse inmediatamente, intenta redistribuir sus claves con nodos hermanos adyacentes.

 - **Ejemplo:** Si un nodo está lleno y su hermano derecho tiene espacio, algunas claves se mueven al hermano para evitar la división.

- Solo si **todos los hermanos están llenos** se procede a dividir el nodo.
- **Mayor Densidad de Almacenamiento**
- **Ocupación mínima garantizada:**
 - En árboles B estándar: Cada nodo debe tener al menos $\lceil m/2 \rceil$ claves.
 - En árboles B*: Cada nodo debe tener al menos $\lceil 2m/3 \rceil$ claves.
 - **Resultado:** Menos nodos y mayor aprovechamiento del espacio (hasta un 66% de ocupación mínima).

Menos Divisiones

- Al redistribuir claves entre nodos hermanos, se reduce la necesidad de crear nuevos nodos, lo que minimiza operaciones de escritura en disco.

Característica	Árbol B	Árbol B+	Árbol B*
Claves en nodos hoja	Sí (todas las claves)	Sí (duplicadas en hojas)	Sí (similar a B+)
Claves en nodos internos	Sí	Solo punteros a hojas	Sí (pero con redistribución)
Ocupación mínima	$\lceil m/2 \rceil$	$\lceil m/2 \rceil$	$\lceil 2m/3 \rceil$
Manejo de overflow	División inmediata	División inmediata	Redistribución primero
Acceso secuencial	Ineficiente	Eficiente (punteros en hojas)	Similar a B+
Uso en bases de datos	Índices secundarios	Índices primarios/clustering	Sistemas con alta inserción

Requisito	Árbol B	Árbol B+	Árbol B*
Acceso secuencial	No recomendado	✓ Ideal	✓ Similar a B+
Altas inserciones	✗ Poco eficiente	✗ Moderado	✓ Óptimo
Espacio en disco limitado	✗ (50% ocupación)	✗ (50% ocupación)	✓ (66% ocupación)
Implementación sencilla	✓ Más simple	✗ Moderada	✗ Compleja
Claves duplicadas	✓ Permitidas	✗ No recomendado	✗ No recomendado

Dispersión (Hashing)

Técnica que convierte una clave en una dirección única para almacenar/recuperar datos rápidamente.

Métodos de Dispersión

1. División:

- **Fórmula:** $h(k) = k \bmod m$, donde m es el tamaño de la tabla.
- **Ejemplo:** Para $k=1234$ y $m=100$, $h(k)=34$.
- **Ventaja:** Simple y rápido.

2. Plegado:

- **Pasos:** Dividir la clave en partes, sumarlas.
- **Ejemplo:** $k=123456 \rightarrow 12+34+56=102$.

3. Cuadrados Centrales:

- **Pasos:** Elevar al cuadrado la clave y tomar dígitos centrales.
- **Ejemplo:** $k=1234 \rightarrow 1234^2=1522756$ → Dígitos centrales: 2275.

Manejo de Colisiones

- **Cubetas (Buckets):** Espacios que almacenan múltiples registros en una misma dirección.
- **Parámetros clave:**
 - **Densidad de empaquetamiento (DE):** $DE = \frac{N^{\circ} \text{ de registros}}{N^{\circ} \text{ de direcciones}}$
 - **Tamaño de cubeta:** Afecta la fragmentación y velocidad de acceso.

Método	Ventajas	Desventajas
División	Simple, rápido	Sensible a patrones de claves
Plegado	Bueno para claves largas	Puede generar colisiones frecuentes
Cuadrados Centrales	Distribución uniforme	Costoso computacionalmente

Dispersión (Hashing)

La **dispersión extensible** es un método de hashing dinámico diseñado para manejar el crecimiento de una tabla de hash de manera eficiente, evitando colisiones excesivas y manteniendo un rendimiento óptimo. A diferencia del hashing estático, donde el tamaño de la tabla es fijo, este método ajusta automáticamente el tamaño de la tabla utilizando un directorio de punteros y buckets (cubetas) que pueden dividirse según sea necesario.

Estructura Básica

- **Directorios:**
 - Tabla de punteros que indexa buckets.
 - Su tamaño crece exponencialmente (en potencias de 2) según la necesidad.
- **Buckets:**
 - Contenedores que almacenan registros.
 - Cada bucket tiene una **profundidad local** (dl), que indica el número de bits utilizados para direccionarlo.
- **Profundidad global** (dg):
 - Número de bits utilizados para indexar el directorio.
 - Relacionado con el tamaño del directorio: $Tamaño\ del\ directorio = 2^{dg}$ $Tamaño\ del\ directorio = 2^{dg}$.

Funcionamiento

1. Inserción:

- Se calcula el hash de la clave y se toman los primeros dg bits para ubicar el bucket correspondiente en el directorio.
- Si el bucket se llena, se divide en dos nuevos buckets, incrementando su profundidad local ($dl+1$).
- Si $dl=dg$, el directorio duplica su tamaño ($dg+1$) para acomodar más buckets.

2. Búsqueda:

- Usa los primeros dg bits del hash para acceder directamente al bucket.